

Síntesis final del proyecto NLP-comercial

Del análisis exploratorio a los insights de negocio — separando engagement comercial del ruido social en un catálogo altamente polarizante, DreamMaker.

Resumen ejecutivo

Este documento reconstruye el proyecto de principio a fin: qué se encontró en el análisis exploratorio, qué preguntas fue generando cada hallazgo, cómo se contrastaron esas preguntas con pruebas estadísticas, y qué insights finales se pueden entregar a DreamMaker, siendo explícito sobre cuáles están confirmados estadísticamente y cuáles son patrones descriptivos que requieren cautela.

La idea central del proyecto, sostenida de principio a fin, es esta: el volumen de interacción y la proporción de interacción responden a lógicas distintas. La proporción (qué tan "limpia" es la conversación) describe eficiencia relativa. El volumen (cuántos clientes potenciales toca la publicación) describe impacto de negocio. Una publicación puede ser "sucia" en proporción y aun así generar más clientes potenciales en términos absolutos que una publicación "limpia" pero de bajo alcance. Ese desacople, confirmado en personajes históricos, parcialmente confirmado en instituciones y modelado estadísticamente en la regresión Binomial Negativa, es el hilo conductor de todo el análisis.

1. La historia del análisis: de lo exploratorio a lo inferencial

1.1 Volumen vs. proporción: la primera gran distinción

El análisis exploratorio mostró de entrada que las métricas de volumen (volumen total, volumen de interés, volumen de ruido, volumen de polarización) siguen distribuciones de tipo power-law: el volumen total tiene mediana de apenas 3 a 6 comentarios pero una media de 19,08, arrastrada por un máximo de 789. Esa asimetría motivó desde el inicio el suavizado bayesiano de las proporciones y, más adelante, la elección de modelos de conteo (Binomial Negativa) en vez de regresión lineal clásica.

A nivel agregado, el ruido social (media 10,52) ya superaba a la señal comercial (media 7,21) en volumen absoluto, primera señal de que la página vive dominada por eventos puntuales de alta viralidad más que por un flujo homogéneo de interés comercial (dinámica event-driven).

Al pasar a proporciones, el panorama cambia: la proporción de interés (media 38%, mediana 39%) y la proporción de polarización (media 37%, mediana 36%) resultan casi idénticas, y la proporción de señal comercial promedia 49% por publicación, un núcleo comercial sano. La proporción de ruido social nunca baja de 15%: no existen publicaciones asépticas. Las críticas directas al producto son prácticamente inexistentes, así que el ruido observado no es rechazo al producto, es ruido sociopolítico exógeno al catálogo.

1.2 Personajes históricos: Pinochet como catalizador exógeno

Con solo 6 publicaciones, Pinochet concentra en promedio 330 comentarios totales por publicación, 107 de señal comercial, 208 de ruido social, 71,5 de interés comercial puro y 184 de polarización política, más de un orden de magnitud por encima del resto de los personajes (que promedian entre 0 y 5,3 comentarios de interés comercial). Un solo posteo de Pinochet llegó a 789 comentarios.

En proporción, sin embargo, Pinochet rinde solo 27% de interés comercial, y Allende 10%, muy por debajo de próceres "limpios" como Manuel Rodríguez (64%), Carrera (51%) o Prat (49%). Ahí aparece el primer desacople explícito del proyecto: los próceres "limpios" ganan en eficiencia relativa pero se estancan en volumen absoluto (3 a 5 comentarios de interés por posteo); Pinochet pierde en eficiencia pero gana la escala (71,5).

El gráfico de ruido social (proporción) versus interés comercial (volumen) fue clave: para casi todo el portafolio de personajes la relación es plana, más ruido no mueve el interés comercial ni un poco. La única publicación que rompe esa horizontalidad es Pinochet. De ahí nació la hipótesis del catalizador: el ruido social no crea interés de compra por sí mismo, pero cuando existe un nicho de compra latente y fuerte, el ruido actúa como multiplicador algorítmico exógeno que expande el alcance y permite que ese interés preexistente se materialice a una escala inédita. Neruda, en el extremo opuesto, confirma el límite de esa hipótesis: 87% de ruido, 85% de polarización y prácticamente cero interés comercial; sin nicho de compra latente, el ruido político simplemente ahoga la conversación.

1.3 Instituciones: el ruido como factor estéril (y la excepción del Ejército)

El bloque institucional invierte varias de las intuiciones anteriores. Carabineros concentra el mayor ruido (media 20,9, desviación estándar 39,3, máximo 112,0) y los mayores niveles de fanatismo no comercial (2,5), con una eficiencia relativa de solo 32%, la más baja del bloque institucional. Aun así, es la institución con mayor volumen absoluto de interés comercial (media 4,2).

Ejército, en cambio, es el contraejemplo directo: con la muestra más robusta del dataset (**24 publicaciones**), promedia solo **1,2 comentarios de ruido social** y un insignificante 0,2 de fanatismo no comercial, mientras que su volumen de interés comercial (media 3,9, muy cercano al de Carabineros) incluye un outlier de **55,0 comentarios de interés en una sola publicación**. Su eficiencia relativa (46%) es muy superior a la de Carabineros (32%). FACH, Armada y PDI, en contraste, son nichos estables de baja interacción y bajo volumen (interés medio entre 1,5 y 2,5).

El gráfico de ruido social (proporción) versus interés comercial (volumen) para instituciones muestra una base plana en casi todo el espectro de contaminación (0,25 a 0,80): las publicaciones de Carabineros se dispersan horizontalmente alcanzando picos extremos de ruido sin que el interés comercial despegue del suelo. La única anomalía vertical es, precisamente, el posteo de Ejército, que logra su récord de 55 comentarios de interés en una zona de baja contaminación (~0,25). Es decir: en instituciones el ruido no actuó como multiplicador (a diferencia de Pinochet); el récord comercial institucional se logró sin polémica.

1.4 Validación estadística: qué sobrevivió al contraste de hipótesis

Kruskal-Wallis junto con epsilon cuadrado (ϵ^2) se usaron para distinguir significancia estadística de tamaño del efecto, decisión clave dado el desbalance muestral entre categorías.

Personajes históricos

Variable	H	p-value	ϵ^2	¿Significativo?
Volumen de ruido	16,18	0,0235	0,765	Sí
Proporción de ruido social	14,26	0,0467	0,605	Sí
Volumen de interés	11,62	0,1136	0,385	No (efecto grande)
Proporción de interés	13,75	0,0558	0,563	Límite (no)

Conclusión: hay evidencia sólida de que los personajes históricos difieren en la dinámica social y de ruido que generan. Las diferencias en interés comercial tienen tamaños de efecto grandes, pero no alcanzan significancia, probablemente por categorías con 1 o 2 publicaciones y por la concentración del interés comercial en pocos eventos de alto impacto (Pinochet).

Instituciones

Variable	H	p-value	ϵ^2
Volumen de interés	1,90	0,7536	≈ 0
Proporción de interés	5,76	0,2177	0,050

Volumen de ruido	5,86	0,2102	0,053
Proporción de ruido social	6,53	0,1629	0,072

Ninguna variable institucional alcanzó significancia global. Pero esto **no equivale** a decir que las instituciones se comportan igual: la muestra está fuertemente desbalanceada (Ejército 24, Carabineros 8, Armada 4, FACH 2, PDI 2), lo que reduce drásticamente la potencia del test para detectar diferencias reales, en particular con grupos de 2 observaciones. Los contrastes post-hoc (Dunn) tampoco sobrevivieron la corrección por comparaciones múltiples, resultado esperable, no evidencia de ausencia de diferencias.

Limitación estructural que aplica a todo el proyecto: el catálogo no es una muestra aleatoria de personajes e instituciones. Es un catálogo generado por decisiones comerciales previas (qué se decidió producir), por lo que existe un posible sesgo de selección. La pregunta que realmente responde el análisis no es "qué categoría genera más interés" sino "dentro de lo que la empresa decidió publicar, qué patrones de interacción se observan".

1.5 El modelo Binomial Negativo: cuantificando los efectos

Con el volumen de interés como variable dependiente ($n=155$, pseudo $R^2=0,2436$, LLR $p<0,001$), el modelo permite aislar el efecto de cada variable controlando por las demás, algo que las comparaciones bivariadas del análisis exploratorio no pueden hacer.

Variable	β	p	IRR ($\approx e^{\beta}$)	Lectura
Proporción de ruido social	-4,69	<0,001	0,009	Fuerte efecto negativo
Carabineros	2,06	<0,001	$\approx 7,82$ (+680%)	Significativo
Ejército	0,41	0,139	$\approx 1,51$ (+51%)	No significativo
Pinochet	4,99	<0,001	muy alto	Significativo (cautela)
Prat	0,60	0,017	$\approx 1,82$ (+82%)	Significativo
O'Higgins	1,35	<0,001	$\approx 3,85$ (+285%)	Significativo
Sin venta / no disponible	-2,43	<0,001	bajo	Significativo (negativo)
Avance de proyecto	-0,65	0,029	bajo	Significativo (negativo)
Con precio	0,40	0,155	—	No significativo
Producto materializado	0,17	0,375	—	No significativo
Allende	0,92	0,238	—	No significativo

El coeficiente de la **proporción de ruido social** ($\beta=-4,69$, $p<0,001$) es, en apariencia, la relación más fuerte del modelo: a mayor proporción de ruido, menor volumen esperado de interés comercial, manteniendo todo lo demás constante. Pero este coeficiente describe el **comportamiento promedio dominante**, que corresponde al régimen de bajo volumen donde se concentra la mayoría de las publicaciones, no es una regla universal, como se ve a continuación con el árbol de decisión.

1.6 El árbol de decisión: regímenes de comportamiento e importancia de variables

La sospecha de que existían distintos regímenes de comportamiento, que el modelo lineal, al estimar una sola pendiente para todo el dataset, no podía capturar, se contrastó con un árbol simple, que identificó dos umbrales de volumen total: aproximadamente 11,5 y 46,5 comentarios.

- Régimen bajo (menos de $\sim 11,5$ comentarios): alta variabilidad en las proporciones. Con pocos comentarios, uno o dos bastan para mover la composición porcentual completa. Sin tendencia clara.

- Régimen intermedio (~11,5 a ~46,5): la proporción de interés comercial se estabiliza en valores altos y el ruido permanece contenido. Aquí la relación "conversación limpia = mayor interés comercial" (el signo del coeficiente de la Binomial Negativa) se cumple con más claridad. Es plausible que buena parte del comportamiento de Ejército, alto volumen y bajo ruido, viva en esta franja.
- Régimen alto (más de ~46,5): la proporción de interés comercial empieza a caer y la de ruido a subir de forma sostenida. Pero el volumen absoluto de interés comercial sigue creciendo, solo que el ruido crece todavía más rápido, diluyendo su participación relativa. Es el régimen donde vive Pinochet.

Esto reconcilia la aparente contradicción entre el coeficiente negativo de la proporción de ruido social y el efecto positivo masivo de Pinochet: ambos son ciertos, pero describen regímenes distintos. En el grueso del portafolio (bajo e intermedio volumen), menos ruido significa más interés. En el régimen viral extremo, más ruido acompaña a más interés absoluto, aunque diluya la proporción; el ruido deja de ser enemigo y pasa a ser combustible de alcance, siempre que exista demanda latente que capturar.

La importancia de variables del árbol (medida como reducción de impureza) confirma que el volumen total es, por lejos, el predictor dominante, pero también identifica otros tres predictores con peso real:

Variable	Importancia
Volumen total	64,6%
Ejército	19,9%
Con precio	8,5%
Producto materializado	7,0%
Otras variables	0%

Dos lecturas se desprenden de esta tabla. Primero, Ejército aparece como el segundo predictor más importante del árbol completo (19,9%), muy por encima de cualquier otra categoría de personaje o institución, lo cual corrobora desde un método independiente (basado en reducción de impureza, no en significancia estadística) el patrón ya observado en el análisis exploratorio y discutido en el **insight 3**. Segundo, tanto "con precio" (8,5%) como "producto materializado" (7,0%) tienen peso no trivial, muy por encima de "otras variables" (0%), lo que confirma que ambas variables sí participan activamente en la estructura del árbol, aunque con una importancia menor que el volumen total y que Ejército. Este punto se retoma en el **insight 6**.

1.7 Aporte comercial acumulado por régimen: la paradoja de la escala

El paso siguiente fue dejar de mirar el promedio por publicación y mirar el acumulado: de todo el interés comercial capturado por la página, qué régimen aporta más en términos netos. La respuesta profundiza, y en cierto sentido corrige el énfasis de, el insight 1: no es solo que el ruido no le hace daño al volumen en el régimen viral; es que el régimen viral es, con enorme diferencia, el que sostiene el negocio.

Régimen	N (%)	Prop. interés prom.	Prop. ruido prom.	Comentarios/post prom.	Interés acumulado (% del total)
R1 — Bajo ($\leq 11,5$)	135 (87,1%)	39,3%	42,9%	3,2	227 (28,6%)
R2 — Intermedio (11,5–46,5)	≈ 11 ($\approx 7,1\%$)*	29,1%	—	—	≈ 62 (7,8%)
R3 — Viral ($> 46,5$)	9 (5,8%)	27,1%	53,9%	257	504 (63,6%)

**El tamaño y el interés acumulado de R2 no se reportaron explícitamente en el análisis original; se derivan por diferencia respecto a R1 y R3 sobre el total de 155 publicaciones y ~794 interacciones de interés. Debe tratarse como cifra estimada, no como dato reportado directamente por el árbol.*

El patrón es contundente: el **87,1% de las publicaciones (R1)**, las más "limpias" en proporción (39,3% de interés), aportan solo **28,6%** del interés comercial total acumulado, porque su volumen individual es minúsculo (3,2 comentarios promedio). En el otro extremo, el **5,8% de publicaciones virales (R3)**, con la eficiencia relativa más baja del conjunto (27,1%) y el mayor nivel de ruido (53,9%), concentran **63,6%** de todo el interés comercial capturado por la página, con un promedio de 56 interacciones de interés por publicación frente a las 1,3 que aporta en promedio una publicación de R1.

Esto matiza, y en la práctica invierte la prioridad de, la lectura puramente proporcional del modelo Binomial Negativo. El coeficiente negativo de la proporción de ruido social ($\beta=-4,69$) sigue siendo cierto como relación promedio, pero a nivel de negocio esa relación gobierna un conjunto de publicaciones que, aun siendo mayoritario en cantidad, es minoritario en el resultado que importa: los clientes potenciales netos capturados. La estrategia comercial no debería leerse como "maximizar la proporción de interés minimizando el ruido", sino como "identificar qué publicaciones logran una respuesta masiva del público y luego evaluar qué fracción de esa atención se convierte en interés comercial". El orden importa, porque intentar maximizar eficiencia en publicaciones pequeñas tiene un techo bajo, mientras que una sola publicación viral puede aportar, por sí sola, más interés acumulado que decenas de publicaciones eficientes.

2. Insights finales para DreamMaker

Los insights siguientes están etiquetados según su nivel de evidencia, para que quede claro qué es hallazgo confirmado y qué es patrón exploratorio con potencial de negocio.

Insight 1 — El ruido no es enemigo del volumen de ventas; es enemigo de la "pureza" de la conversación

Confirmado estadísticamente + patrón consistente en el análisis exploratorio

Publicaciones más polémicas no implican, por sí mismas, menos interés comercial absoluto. Al contrario: por encima del umbral de viralidad identificado por el árbol (~46,5 comentarios), un mayor volumen de ruido social convive con un mayor volumen absoluto de interés comercial. El caso Pinochet es la evidencia más nítida (71,5 comentarios de interés comercial promedio, $\beta=4,99$, $p<0,001$ en el modelo, muy por encima de cualquier otra categoría), y el gráfico de ruido (proporción) versus interés (volumen) muestra que su publicación es la única que rompe la línea de base plana del resto del portafolio de personajes. Lo que sí cae con el ruido es la proporción y eficiencia de la conversación, no el número absoluto de clientes potenciales capturados.

El análisis de aporte acumulado por régimen (sección 1.7) cuantifica esto a nivel de negocio: el **5,8% de publicaciones que caen en el régimen viral (más de 46,5 comentarios) concentra el 63,6% de todo el interés comercial acumulado de la página**, pese a tener la eficiencia relativa más baja (27,1% de interés versus 53,9% de ruido). El 87,1% de publicaciones "limpias" y de bajo volumen, en cambio, solo aporta 28,6% del interés total, aun siendo la mayoría absoluta del catálogo. Es la confirmación más directa, a nivel agregado, de que optimizar por proporción y limpieza tiene un techo de negocio bajo, y que la estrategia de crecimiento pasa por identificar contenido con capacidad de amplificación, no por evitar el ruido.

Insight 2 — Existen dos rutas de éxito comercial, no una sola

Patrón descriptivo consistente, con distinto grado de soporte estadístico según variable

- **Ruta viral / polémica:** Pinochet (personajes) y Carabineros (instituciones). Escala máxima de alcance y de interés comercial absoluto, a costa de baja eficiencia relativa (27% y 32% respectivamente) y alto ruido y fanatismo no comercial.
- **Ruta limpia / nicho:** Ejército (instituciones) y próceres tradicionales como O'Higgins, Prat, Carrera y Manuel Rodríguez (personajes). Conversación mucho más enfocada en el producto (eficiencia 46% a 64%), con menor ruido, y capaz de alcanzar picos comerciales altos sin polémica. El máximo histórico de la muestra en una sola publicación (55 comentarios de interés) corresponde a Ejército, en zona de baja contaminación de ruido (~25%).

Ambas rutas generan valor. La decisión de negocio no es "evitar" ni "buscar" la polémica en abstracto, sino reconocer que el retorno esperado depende de si existe una demanda de nicho latente detrás del tema (ver insight 3).

Insight 3 — Carabineros vs. Ejército: dos rutas de éxito con distinto nivel de evidencia

Insight de negocio recomendado, con evidencia corroborada por dos métodos independientes; el coeficiente lineal de Ejército no es estadísticamente significativo

Tiene sentido incluir a Ejército como insight relevante para DreamMaker, siempre que se presente con el nivel de evidencia correcto: como patrón descriptivo y de negocio respaldado por dos métodos independientes, no como hallazgo confirmado por un test de significancia estadística.

- El árbol de decisión identifica a Ejército como una franja "limpia" relevante (bajo ruido, alto volumen relativo) de forma consistente con el análisis exploratorio: Ejército tiene el segundo mayor volumen medio de interés comercial entre instituciones (3,9, solo detrás de Carabineros con 4,2), con la muestra más grande y robusta del bloque (24 publicaciones) y el récord absoluto de interés en un solo posteo (55,0).
- La importancia de variables del árbol (sección 1.6) refuerza este patrón desde un ángulo distinto: Ejército es el segundo predictor más importante de todo el modelo (19,9%), superado únicamente por el volumen total (64,6%) y muy por encima de cualquier otra categoría específica. Esta es evidencia independiente del modelo lineal, obtenida por un método distinto (reducción de impureza en vez de significancia estadística), y apunta en la misma dirección.

El modelo Binomial Negativo sí le asigna un coeficiente positivo y de magnitud considerable ($\beta=0,41$, $IRR\approx 1,51$, es decir +51% de interés esperado respecto a la categoría base), **consistente en dirección** con el análisis exploratorio y con el árbol, pero no alcanza significancia ($p=0,139$). Esto no significa que el efecto no exista; significa que, con la evidencia disponible, no se puede descartar que sea producto del azar muestral.

El porqué de esa falta de significancia en el modelo lineal está documentado en el análisis exploratorio y de supuestos: el catálogo institucional está fuertemente desbalanceado (Ejército 24 posteos frente a Armada, FACH y PDI con 2 a 4), Kruskal-Wallis tampoco encontró diferencias globales significativas entre instituciones para el volumen de interés ($H=1,90$, $p=0,7536$), y el catálogo no es una muestra aleatoria: la cantidad de publicaciones por institución probablemente refleja decisiones comerciales previas, no solo el potencial real de cada temática. Con muestras tan chicas y desbalanceadas, es esperable que el modelo lineal tenga poca potencia para separar a Ejército de la categoría base, incluso si el efecto descriptivo es real y aparece corroborado por el árbol.

Lectura recomendada: dos hallazgos de distinto peso, no una sola conclusión. Carabineros genera el mayor volumen comercial institucional de forma estadísticamente confirmada ($\beta=2,06$, $p<0,001$, +680% respecto a la categoría base), pero a costa de un ruido social desproporcionado (media 20,9 versus 1,2 de Ejército) y de la menor eficiencia relativa del bloque (32%). Ejército genera un volumen comercial casi comparable (3,9 versus 4,2) con una conversación mucho más limpia (46% de eficiencia) y su propio récord absoluto de interés comercial en una publicación (55 comentarios), patrón respaldado tanto por el análisis exploratorio como por la importancia de variables del árbol, aunque el modelo lineal todavía no le asigna significancia estadística formal. Antes de escalar la estrategia exclusivamente en torno a Ejército conviene ampliar su muestra de publicaciones para ganar potencia estadística.

Insight 4 — Excluir explícitamente lo que no es intención de compra

Confirmado estadísticamente

Las publicaciones sin venta o no disponibles ($\beta=-2,43$, $p<0,001$) y las de avance de proyecto ($\beta=-0,65$, $p=0,029$) reducen significativamente el interés comercial esperado. Esto valida separar, en el reporting de negocio, las publicaciones de producto disponible de las de avance de proyecto o no disponible: mezclar ambas categorías subestima el verdadero interés comercial de los productos que sí están a la venta.

Insight 5 — La "limpieza" conversacional no está negativamente correlacionada con el volumen de interés; están, de hecho, poco correlacionadas entre sí

Patrón exploratorio robusto en múltiples cortes del análisis

En instituciones, la eficiencia relativa (FACH 55%, PDI 51%, Armada 48%, Ejército 46%, Carabineros 32%) tiene un orden casi inverso al del volumen absoluto (Carabineros 4,2, Ejército 3,9, Armada y FACH 2,5, PDI 1,5). En personajes ocurre lo mismo: los próceres más "limpios" (Manuel Rodríguez 64%) tienen los volúmenes más bajos (3 a 5 comentarios), mientras que Pinochet, con la eficiencia más baja del grupo relevante (27%), tiene el volumen más alto por lejos (71,5). Esto es evidencia consistente de que optimizar exclusivamente por proporción y eficiencia (una conversación "estéticamente" limpia) puede ir en contra del objetivo real de negocio, que es maximizar el volumen neto de clientes potenciales capturados.

Insight 6 — El producto materializado tiene peso real, aunque modesto, tanto en el modelo como en el árbol

Confirmado como señal relevante en dos métodos, con dirección plausible pero no completamente verificada

En el modelo Binomial Negativo, la variable de producto materializado tiene un coeficiente positivo ($\beta=0,17$, $IRR \approx 1,19$, es decir +19% de interés esperado) al controlar por el resto de variables, pero **no alcanza significancia estadística ($p=0,375$)**. Es un peso presente pero débil sobre el volumen de interés comercial.

La importancia de variables del árbol (sección 1.6) añade una segunda pieza de evidencia: producto materializado aparece con 7,0% de importancia, el más bajo de los tres predictores categóricos identificados por el árbol (volumen total 64,6%, Ejército 19,9%, con precio 8,5%), pero muy por encima de "otras variables" (0%). Esto confirma que la variable participa activamente en la estructura del árbol y que la señal no es inventada: es real, aunque modesta y menor que la de Ejército o de con precio.

El sentido exacto de esa relación (si materialización se asocia específicamente con una mayor **proporción** de interés, es decir con publicaciones "más limpias", y no solo con mayor volumen) es plausible y coherente con el signo positivo del coeficiente del modelo, pero no queda completamente verificado sin revisar las reglas de split del árbol en detalle (qué umbral y en qué dirección divide la variable en cada nodo). Con la evidencia de importancia agregada disponible se puede afirmar que la variable importa; para afirmar con precisión hacia qué proporción específica empuja, conviene revisar la estructura completa del árbol.

3. Conclusión general del proyecto

La historia completa del proyecto puede resumirse así: el análisis exploratorio reveló que la página vive dominada por eventos de alta viralidad más que por un flujo constante de interés comercial, y que separar volumen de proporción era indispensable para no confundir eficiencia con impacto. El análisis por categoría mostró que esa separación no es cosmética: personajes e instituciones "limpios" ganan en proporción pero pierden en escala, y viceversa. Las pruebas de hipótesis confirmaron diferencias reales en la dinámica social entre personajes históricos, pero no lograron (por limitaciones de tamaño y desbalance muestral, no necesariamente por ausencia real de efecto) confirmar diferencias comerciales entre instituciones con el mismo nivel de certeza. El modelo Binomial Negativo cuantificó lo anterior: el ruido social, en promedio, perjudica el interés comercial esperado ($\beta=-4,69$), salvo en los casos extremos de viralidad (Pinochet, Carabineros) donde actúa como multiplicador de alcance. El árbol de decisión explicó por qué ambas cosas son ciertas a la vez: existen regímenes distintos de comportamiento según el volumen total de la conversación, algo que un modelo de pendiente única no puede representar, y su análisis de importancia de variables aportó una segunda fuente de evidencia, independiente del modelo lineal, que corrobora el peso de Ejército, de con precio y de producto materializado.

El análisis de aporte acumulado por régimen (sección 1.7) fue el que terminó de zanjar la pregunta de negocio: no se trata solo de que el ruido no perjudique el volumen en el extremo viral, sino de que ese extremo viral, apenas 5,8% de las publicaciones, sostiene 63,6% de todo el interés comercial capturado por la página, mientras que el 87,1% de publicaciones "limpias" y pequeñas aporta menos de un tercio del total. Esto reordena la prioridad estratégica: el objetivo no debería ser

maximizar la proporción de conversación comercial publicación por publicación, sino identificar qué contenido tiene capacidad de generar una respuesta masiva del público, y solo después evaluar qué fracción de esa atención se convierte en interés de compra.

Para DreamMaker, la implicancia estratégica central es que no existe una única palanca de crecimiento. Hay una vía de escala vía viralidad y polémica (con costos de ruido y menor pureza conversacional, pero mayor techo absoluto) y una vía de nicho limpio (menor techo, pero conversación más eficiente y menos fricción operativa y reputacional). La evidencia sugiere que ambas pueden convivir en el portafolio, y que la pregunta relevante para cada nueva línea de producto no es "esto generará ruido" sino "existe una demanda de nicho latente detrás de este tema que el ruido pueda amplificar, o el ruido reemplazará a un interés comercial que de otro modo no existiría". La comparación Pinochet/Allende y Carabineros/Ejército, tomadas en conjunto, son el mejor indicio disponible en los datos actuales para responder esa pregunta caso a caso.

4. Limitaciones y próximos pasos

- El catálogo no es una muestra aleatoria de temáticas: refleja decisiones comerciales previas, por lo que existe sesgo de selección potencial en qué categorías tienen más publicaciones.
- Los tamaños muestrales por categoría son muy desiguales (de 2 a 24 publicaciones), lo que reduce la potencia estadística disponible para detectar diferencias reales, especialmente en el bloque institucional.
- Ninguna variable del dataset sigue una distribución normal (Shapiro-Wilk rechazado en todos los casos), lo que descarta pruebas paramétricas clásicas y motivó el uso de métodos no paramétricos y modelos de conteo.
- El coeficiente de Neruda ($\beta = -21,05$) es un artefacto de cuasi-separación (una sola publicación, sin interés comercial observado) y no debe interpretarse como un efecto poblacional estimado con precisión.
- La dirección exacta de la relación entre producto materializado y proporción de interés (insight 6) no está verificada a nivel de reglas de split del árbol; solo se confirmó su importancia agregada.
- Próximo paso natural: aumentar la muestra de publicaciones de Ejército y de otras instituciones pequeñas (FACH, PDI, Armada) antes de tratar sus coeficientes como confirmados, revisar las reglas de split completas del árbol para precisar la dirección de con precio y de producto materializado, y complementar el modelo con validación cruzada temporal, dado el cambio estructural de contenidos detectado desde 2020.